Lista chequeo act 4

Criterios	Calificaciones	Pts
Este criterio depende de una competencia de aprendizaje Instalación de las librerías de datasets y SentencePiece.	**0.25 pts100%** **0.2 pts80%** **0.15 pts60%** **0.1 pts40%** **0.05 pts20%** **0 pts0%**	0.25 pts
Este criterio depende de una competencia de aprendizaje Carga del dataset Word Billion desde Hugging Face. Tener en cuenta que es un dataset de 47 millones de filas=4.7Gz	**0.5 pts100%** **0.4 pts80%** **0.3 pts60%** **0.2 pts40%** **0.1 pts20%** **0 pts0%**	0.5 pts

Este criterio depende de una competencia de aprendizaje Implementar una rutina para que el dataset Word Billion pueda ser procesado. Para ello se deberá particionar el dataset en un conjunto de archivos de texto. Estos archivos de texto deben ser guardados en un directorio.	**1 pts100%** **0.8 pts80%** **0.6 pts60%** **0.4 pts40%** **0.2 pts20%** **0 pts0%**	1 pts

Este criterio depende de una competencia de aprendizaje Entrenar el tokenizador SentencePiece sobre el conjunto de archivos de texto. Para ello se deberá tener en cuenta el tamaño del vocabulario, el modelo del prefijo='m' y el archivo del modelo resultante.	**0.75 pts100%** **0.6000000000000001 pts80%** **0.4499999999999996 pts60%** **0.30000000000000004 pts40%** **0.15000000000000002 pts20%** **0 pts0%**	0.75 pts

Este criterio depende de una competencia de aprendizaje Entrenar el tokenizador SentencePiece sobre el conjunto de archivos de texto y tokenizar 5 sentencias. Para ello se deberá tener en cuenta; los tamaños de vocabulario de 10000, 20000 y 30000, el modelo del prefijo='bpe' y el archivo del modelo resultante.	**1 pts100%** **0.8 pts80%** **0.6 pts60%** **0.4 pts40%** **0.2 pts20%** **0 pts0%**	1 pts

Este criterio depende de una competencia de aprendizaje Entrenar el tokenizador SentencePiece sobre el conjunto de archivos de texto y tokenizar 5 sentencias. Para ello se deberá tener en cuenta; los tamaños de vocabulario de 10000, 20000 y 30000, el modelo del prefijos de WordPiece <sep>, y <cls> y el archivo del modelo resultante.	**0.75 pts100%** **0.6000000000000001 pts80%** **0.4499999999999996 pts60%** **0.30000000000000004 pts40%** **0.15000000000000002 pts20%** **0 pts0%**	0.75 pts

Este criterio depende de una competencia de aprendizaje Entrenar el tokenizador SentencePiece sobre el conjunto de archivos de texto y tokenizar 5 sentencias. Para ello se deberá tener en cuenta; los tamaños de vocabulario de 10000, 20000 y 30000, el modelo del prefijo es tipo 'char' y el archivo del modelo resultante.	**0.75 pts100%** **0.6000000000000001 pts80%** **0.4499999999999996 pts60%** **0.30000000000000004 pts40%** **0.15000000000000002 pts20%** **0 pts0%**	0.75 pts